

Marco Ensemble de Aprendizaje Profundo Multimodal para la Detección de Cáncer de Piel

Aymen Bellakhal

Universidad de Córdoba
[correo@uco.es]

Resumen El diagnóstico temprano del cáncer de piel es un reto fundamental en la salud actual, y la inteligencia artificial se ha convertido en una herramienta clave para mejorar la precisión de los diagnósticos. Este trabajo analiza el artículo “*Multimodal deep learning ensemble framework for skin cancer detection*” [1], que propone un sistema avanzado capaz de combinar las imágenes de las lesiones con datos clínicos del paciente —como la edad o el sexo— para no depender exclusivamente de la información visual. Lo más destacado de esta propuesta es que utiliza un sistema de ensemble que decide automáticamente en qué modelos confiar más según el caso, logrando resultados muy sólidos incluso con datos que el sistema no había visto antes. Además, el estudio explica cómo solucionaron problemas comunes, como la falta de imágenes para ciertos tipos de cáncer poco frecuentes. En este informe se detalla el funcionamiento de esta tecnología, se analizan sus resultados y se ofrece una valoración crítica sobre su utilidad y sus posibles mejoras.

Keywords: Aprendizaje profundo · Cáncer de piel · Metadatos clínicos · Clasificación de imágenes · Inteligencia artificial

Índice general

1		
1	Introducción	3
2	Antecedentes	4
	2.1 Aprendizaje por transferencia (<i>Transfer Learning</i>)	4
	2.2 Uso de datos clínicos (Metadatos)	4
	2.3 Técnicas de combinación de modelos (<i>Ensemble</i>)	4
3	Metodología	5
	3.1 Conjuntos de datos	5
	3.2 Preprocesamiento	5
	3.3 Arquitectura del modelo	6
	3.4 Técnica de ensemble adaptativo con pesos dinámicos . . .	7
4	Evaluación experimental	8
	4.1 Configuración experimental	8
	4.2 Resultados sobre ISIC 2018 e ISIC 2019	8
	4.3 Validación externa en el conjunto Derm7pt	10
5	Análisis crítico	11
6	Conclusión	13

1. Introducción

El cáncer de piel es una de las enfermedades más frecuentes y peligrosas que existen hoy en día a nivel mundial. Detectarlo a tiempo es clave para que el tratamiento funcione y el paciente tenga posibilidades reales de recuperarse. Hasta hace no mucho, el diagnóstico dependía casi siempre del ojo del dermatólogo, lo cual era un problema porque los resultados variaban mucho dependiendo de la experiencia que tuviera el médico.

Con la aparición del aprendizaje profundo (*deep learning*), el análisis de imágenes médicas ha avanzado muchísimo. Las redes neuronales convolucionales (CNN) han demostrado que pueden clasificar lesiones en la piel con una precisión similar o incluso superior a la de un experto, lo que ha hecho que esta sea una de las áreas donde más se investiga actualmente.

Sin embargo, hay un problema importante: la mayoría de los modelos que se proponen solo miran la foto de la lesión y se olvidan de otros datos clínicos del paciente, como su edad, su sexo o la parte del cuerpo donde está la mancha. Otro reto es que las bases de datos que usamos para entrenar a estas máquinas suelen estar muy desequilibradas, con muchísimos ejemplos de lesiones comunes y muy pocos de tipos de cáncer que se ven menos.

El artículo que analizo en este trabajo, titulado “*Multimodal deep learning ensemble framework for skin cancer detection*” [1], intenta resolver estos problemas a la vez. Sus autores proponen usar tanto las imágenes como los datos clínicos del paciente, aplicar un sistema de ensemble inteligente que decide qué modelos funcionan mejor, y utilizar una técnica llamada SMOTE para equilibrar los datos y que el sistema aprenda igual de bien sobre todos los tipos de cáncer.

Este informe está organizado de la siguiente manera: en la Sección 2 revisaremos qué se ha hecho antes en este campo; en la Sección 3 explicaré paso a paso la metodología del artículo; en la Sección 4 veremos los resultados de sus experimentos; y finalmente, en las Secciones 5 y 6 daré mi opinión crítica y las conclusiones finales.

2. Antecedentes

El estudio de cómo clasificar las manchas en la piel de forma automática se ha realizado de muchas formas distintas en los últimos años. En esta sección resumimos las líneas principales que han precedido a la propuesta del artículo analizado.

2.1. Aprendizaje por transferencia (*Transfer Learning*)

El uso de modelos pre-entrenados sobre grandes bases de datos de imágenes generales (p. ej., ImageNet) como punto de partida para la clasificación de imágenes médicas es una práctica consolidada. Liao [2] fue uno de los primeros en aplicar *transfer learning* sobre CNN profundas para la clasificación de enfermedades cutáneas, mientras que Kawahara et al. [3] exploraron el uso de CNN como extractores de características para imágenes no dermatoscópicas. Más recientemente, Bibi et al. [4] propusieron una arquitectura que fusiona DarkNet-53 y DenseNet-201 con selección de características mediante algoritmos evolutivos, alcanzando un 85.4 % de precisión en ISIC 2018.

Nugroho et al. [5] incidieron en la importancia del preprocesamiento y el balanceo de datos en ISIC 2019 usando Inception-V3, DenseNet-201 y Xception, alcanzando un 88.63 % con Inception-V3 tras un extenso proceso de aumentación de datos.

2.2. Uso de datos clínicos (Metadatos)

La incorporación de información clínica del paciente junto con las imágenes representa una tendencia creciente. Gessert et al. [6] demostraron que integrar edad, sexo y localización anatómica mediante una rama densa paralela a la CNN mejora la precisión balanceada hasta un 74.2 % en ISIC 2019. Sun et al. [7] emplearon EfficientNet-B3/B4 con fusión de metadatos, *test-time augmentation* y corrección de color, alcanzando un 89.5 % en ISIC 2018 y siendo situados en lo más alto del *leaderboard* de ISIC. Yin et al. [8] propusieron los módulos MetaNet y MetaBlock sobre DenseNet-169, obteniendo una mejora de hasta un 15.6 % sobre modelos basados únicamente en imágenes.

2.3. Técnicas de combinación de modelos (*Ensemble*)

Las técnicas de ensemble son ampliamente usadas para mejorar la robustez y reducir la varianza de los modelos individuales. Amiri et al. [9] combinaron Inception-ResNet v2 y EfficientNet-B4 con votación suave, alcanzando un 88.21 % en ISIC 2018. Tabibi et al. [10] emplearon una combinación de ConvNext-Tiny, EfficientNetB0, SENet, DenseNet y ResNet50, logrando un 90.15 %. Firat y Üzen [11] propusieron DXDSENet-CM, un ensemble que integra Xception, DenseNet201 y un ConvMixer con mecanismos de atención, alcanzando también un 88.21 % en ISIC 2018. Estos antecedentes evidencian la

efectividad de los enfoques ensemble, aunque ninguno de los trabajos referenciados combina simultáneamente la fusión de metadatos con pesos de ensemble aprendidos adaptativamente.

3. Metodología

3.1. Conjuntos de datos

Para que el modelo sea fiable, los autores lo probaron con tres colecciones de imágenes distintas [1]:

- **ISIC 2018** [16]: Base de datos ampliamente utilizada que contiene unas 10 015 imágenes de lesiones dermatoscópicas divididas en 7 categorías de enfermedades.
- **ISIC 2019** [17]: Más grande que la anterior, con unas 25 331 imágenes y añade el carcinoma de células escamosas (SCC) como octava categoría. Un problema común en ambas es el marcado desbalance de clases: abundan los nevus (NV) y escasean otros cánceres raros.
- **Derm7pt** [18]: Se usó como prueba externa. Contiene más de 2 000 imágenes clínicas y dermos-cópicas que permiten evaluar la capacidad de generalización del modelo a datos de un dominio distinto.

Característica	ISIC 2018	ISIC 2019	Derm7pt
Nº imágenes	~10.015	~25.331	>2.000
Nº clases	7	8	6
Tipo de imágenes	Dermatoscópicas	Dermatoscópicas	Clínicas + Dermoscópicas
Uso en el estudio	Entrenamiento/test	Entrenamiento/test	Validación externa

Figura 1. Comparativa de los conjuntos de datos utilizados en el estudio [1].

3.2. Preprocesamiento

Como los datos son de dos tipos (imágenes y texto), se crearon dos ramas distintas de preprocesamiento [1]:

- **Preparación de imágenes:** Todas las imágenes se redimensionan a 224×224 píxeles. Se aplica aumentación de datos con rotaciones aleatorias ($\pm 30^\circ$), volteaos horizontales, traslaciones, recortes y ajustes de brillo y contraste.
- **Preparación de metadatos clínicos:** Se seleccionan variables como la edad aproximada del paciente (`age_approx`), la localización anatómica (`anatom_site_general`), el sexo y el estado maligno/benigno. Los valores ausentes se imputan con la media (numéricos) o con el valor “*unknown*” (categóricos). Las variables categóricas se transforman mediante *One-Hot Encoding* y las numéricas se estandarizan con z-score.

- **Balanceo con SMOTE:** Debido al desequilibrio entre clases, se aplica SMOTE (*Synthetic Minority Over-sampling Technique*) [15] sobre los metadatos de entrenamiento, generando muestras sintéticas de las clases minoritarias por interpolación.

3.3. Arquitectura del modelo

El sistema se compone de dos ramas paralelas que se fusionan en una etapa final [1]:

- **Rama visual:** Se emplean tres CNN pre-entrenadas en ImageNet: ResNet50 [12], Xception [13] y EfficientNetB0 [14], seleccionadas por su alto rendimiento frente a MobileNet y DenseNet121. Cada modelo extrae mapas de características reducidos mediante *GlobalAveragePooling2D*, seguidos de *Dropout(0.5)*, *BatchNormalization* y una capa densa de 64 neuronas con activación ReLU.
- **Rama clínica:** Los metadatos se procesan a través de capas densas de 32 y 64 neuronas con activación ReLU, *Dropout(0.5)* y *BatchNormalization*.
- **Fusión multimodal:** Ambas ramas se concatenan y la representación resultante pasa por *Dropout(0.6)*, seguida de una capa Softmax de salida con 7 u 8 neuronas según el conjunto de datos.

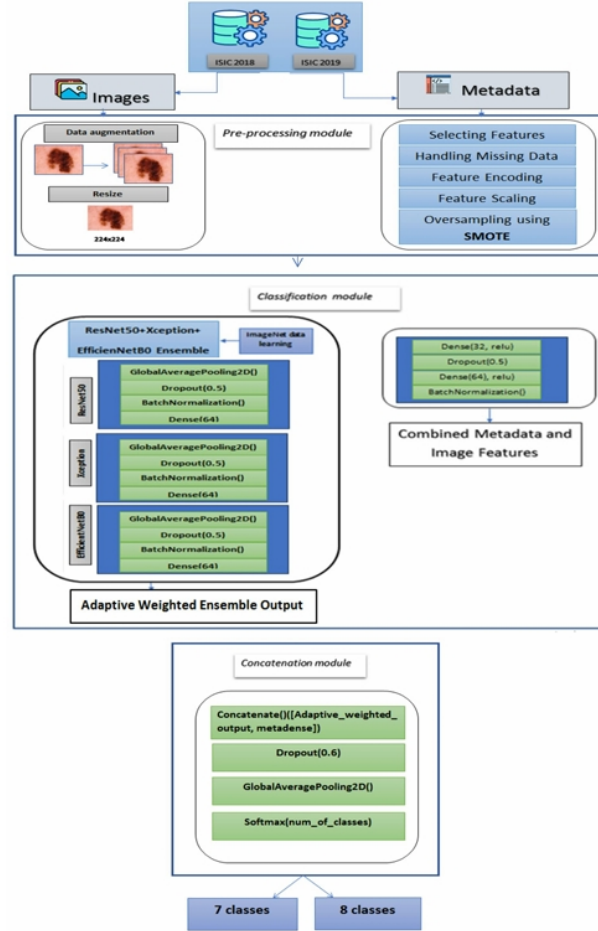


Figura 2. Esquema del workflow del modelo propuesto para ISIC 2018 e ISIC 2019 [1].

3.4. Técnica de ensemble adaptativo con pesos dinámicos

La contribución técnica central del artículo [1] es el mecanismo de ensemble adaptativo. A diferencia de los enfoques convencionales con pesos fijos, el sistema incorpora una capa de pesos entrenables que aprende dinámicamente la contribución de cada modelo base (ResNet50, Xception y EfficientNetB0) en función de su rendimiento en validación.

La predicción final es una combinación ponderada de las salidas de los tres modelos, donde los pesos se optimizan durante el entrenamiento mediante retropropagación. El entrenamiento se realiza con el optimizador Adam ($\text{lr} = 0.0001$), durante 100 épocas máximo con *early stopping* (paciencia 10) y reducción de la tasa de aprendizaje (factor 0.2, paciencia 5).

4. Evaluación experimental

4.1. Configuración experimental

Los experimentos se diseñaron en tres fases progresivas [1]. En el **Experimento 1** se evalúan los cinco modelos CNN individualmente usando únicamente imágenes, sin metadatos. En el **Experimento 2** se incorporan los metadatos clínicos mediante la arquitectura de fusión descrita. En el **Experimento 3** se comparan tres técnicas de ensemble: promedio simple, apilamiento y ensemble adaptativo ponderado.

La división del conjunto de datos sigue una proporción 80/10/10 para entrenamiento, validación y test. Las métricas de evaluación empleadas son: exactitud (*accuracy*), precisión, *recall*, F1-score, especificidad y AUC.

4.2. Resultados sobre ISIC 2018 e ISIC 2019

Los resultados del Experimento 1 muestran que Xception [13] es el mejor modelo individual con un 83.4 % de precisión en ambos conjuntos, seguido de EfficientNetB0 [14] y ResNet50 [12]. MobileNet presenta el peor rendimiento (77.6 % en ISIC 2018 y 73.2 % en ISIC 2019), probablemente debido a su arquitectura ligera diseñada para dispositivos con recursos limitados.

Model Name	Accuracy	Precision	Recall	F1 score
MobileNet	0.776	0.82	0.77	0.78
Xception	0.834	0.85	0.83	0.84
ResNet50	0.825	0.85	0.82	0.83
EfficientNetB0	0.823	0.82	0.82	0.81
DenseNet121	0.814	0.85	0.81	0.82

Figura 3. Resultados experimentales en ISIC 2018 utilizando modelos pre-entrenados antes de la integración de metadatos [1].

Model Name	Accuracy	Precision	Recall	F1 score
MobileNet	0.732	0.72	0.72	0.71
Xception	0.834	0.83	0.83	0.83
ResNet50	0.787	0.78	0.79	0.78
EfficientNetB0	0.821	0.80	0.82	0.82
DenseNet121	0.772	0.76	0.77	0.76

Figura 4. Resultados experimentales en ISIC 2019 utilizando modelos pre-entrenados antes de la integración de metadatos [1].

La incorporación de metadatos (Experimento 2) produce mejoras estadísticamente significativas en todos los modelos (test t pareado, $p < 0,05$) [1]. EfficientNetB0 [14] experimenta la mejora más pronunciada: en ISIC 2018 pasa de un 82.3 % a un 89.7 % (+9 %), y en ISIC 2019 de un 82.1 % a un 87.8 % (+6.9 %).

Model Name	Accuracy	Precision	Recall	F1 score
MobileNet	0.816	0.86	0.81	0.82
Xception	0.880	0.87	0.88	0.88
ResNet50	0.875	0.88	0.87	0.85
EfficientNetB0	0.897	0.88	0.89	0.89
DenseNet121	0.854	0.86	0.85	0.85

Figura 5. Resultados experimentales en ISIC 2018 con modelos pre-entrenados tras la integración de metadatos [1].

Model name	Accuracy	Precision	Recall	F1 score
MobileNet	0.764	0.76	0.76	0.75
Xception	0.863	0.85	0.86	0.86
ResNet50	0.832	0.82	0.83	0.83
EfficientNetB0	0.878	0.88	0.87	0.87
DenseNet121	0.794	0.78	0.79	0.78

Figura 6. Resultados experimentales en ISIC 2019 con modelos pre-entrenados tras la integración de metadatos [1].

El ensemble adaptativo (Experimento 3) consigue la mejor marca en ambos conjuntos: 93.2 % de *accuracy* y 97.3 % de AUC en ISIC 2018, y 91.1 % de *accuracy* con 95.5 % de AUC en ISIC 2019. La diferencia frente al promedio simple es de aproximadamente 0.6 puntos porcentuales en *accuracy* y 1.1 puntos en AUC en ISIC 2018, confirmando la ventaja de la ponderación dinámica [1].

Técnica de Ensemble	Accuracy	Precisión	Recall	F1	AUC
Apilamiento (Stacking)	0.907	0.91	0.91	0.91	0.940
Promedio simple	0.926	0.92	0.93	0.92	0.962
Ensemble adaptativo (propuesto)	0.932	0.93	0.93	0.93	0.973

Figura 7. Rendimiento del ensemble adaptativo propuesto frente a otras técnicas de ensemble en ISIC 2018 [1].

A nivel de clase, el modelo muestra un rendimiento excelente en MEL (*recall* = 1.000 en ISIC 2018) y NV ($F1 = 0.984$), pero encuentra dificultades en las clases minoritarias como AK ($F1 = 0.481$) y DF ($F1 = 0.606$), lo que refleja el reto inherente al desbalance de clases incluso tras aplicar SMOTE [15].

4.3. Validación externa en el conjunto Derm7pt

Para validar la generalización, el modelo se evalúa directamente sobre Derm7pt [18] sin reentrenamiento ni ajuste fino. Se obtiene un 82.5 % de *accuracy*, 86 % de precisión, 83 % de *recall*, 84 % de F1 y un AUC de 89.15 % [1]. La caída de 13 puntos respecto a la validación interna (95.4 %) es esperable dado el cambio de dominio entre datasets. Nevus ($F1 = 0.959$) y BCC ($F1 = 0.927$) son las clases mejor clasificadas, mientras que Dermatofibroma ($F1 = 0.240$) y Lesión vascular ($F1 = 0.456$) presentan los peores resultados, lo que puede atribuirse

al reducido número de muestras de estas clases en Derm7pt (20 y 29 imágenes, respectivamente).

5. Análisis crítico

El trabajo analizado [1] representa una contribución sólida al campo de la clasificación de lesiones cutáneas mediante aprendizaje profundo. Un análisis riguroso permite identificar tanto sus fortalezas como sus limitaciones.

Fortalezas del trabajo

La integración de metadatos clínicos junto con las imágenes es una decisión metodológicamente acertada y bien motivada. Los tests estadísticos pareados aportan evidencia cuantitativa de la mejora ($p < 0,05$ en todas las métricas), reforzando la credibilidad de los resultados. El ensemble adaptativo con pesos dinámicos es una contribución técnica novedosa que va más allá de los enfoques de ensemble convencionales como los de Amiri et al. [9] o Tabibi et al. [10]. La evaluación en un conjunto externo (Derm7pt [18]) es un paso importante hacia la validación de la generalización del modelo, algo que muchos trabajos previos en la literatura omiten.

Limitaciones y aspectos mejorables

En primer lugar, SMOTE [15] se aplica exclusivamente sobre los metadatos y no directamente sobre las imágenes. Aunque la aumentación de datos actúa como complemento, el desbalance de clases en las imágenes no queda completamente corregido, como evidencian los bajos valores de F1 en clases como AK o DF.

Por otro lado, la comparación con trabajos como Gessert et al. [6] —que reportan *balanced accuracy* (74.2 %)— no es del todo equitativa, ya que dicha métrica es más exigente que la *accuracy* estándar cuando existe desbalance de clases.

El modelo ensemble combina tres redes profundas de gran tamaño (ResNet50 [12] con ~ 25.6 M parámetros, Xception [13] con ~ 22.9 M y EfficientNetB0 [14] con ~ 5.3 M), lo que supone un alto coste computacional que puede dificultar su uso en entornos clínicos con recursos limitados.

Las visualizaciones Grad-CAM son cualitativamente informativas pero no se realiza ningún análisis cuantitativo de la interpretabilidad. Un estudio con dermatólogos expertos sería necesario para validar clínicamente la relevancia de las regiones de atención.

Finalmente, el conjunto Derm7pt [18] presenta un fuerte desequilibrio (575 imágenes de Nevus frente a 20 de Dermatofibroma), lo que dificulta la interpretación del rendimiento por clase en la validación externa.

Posibles líneas de trabajo futuro

A partir de las limitaciones identificadas, se proponen las siguientes líneas: (1) aplicación de redes generativas adversariales (GAN) para la síntesis de imágenes de clases minoritarias; (2) exploración de arquitecturas *Vision Transformer* (ViT) o híbridas CNN-ViT; (3) diseño de un protocolo de validación prospectivo

en entornos clínicos reales; (4) análisis de la contribución individual de cada metadato mediante técnicas como SHAP; y (5) compresión del ensemble mediante *knowledge distillation* para su despliegue en dispositivos de bajo coste.

6. Conclusión

El artículo analizado [1] propone un framework multimodal de aprendizaje profundo que combina *transfer learning* [12,13,14], integración de metadatos clínicos y ensemble adaptativo para la clasificación de cáncer de piel. Los resultados obtenidos —93.2 % de *accuracy* en ISIC 2018 [16] y 91.1 % en ISIC 2019 [17]— suponen una mejora notable frente al estado del arte, especialmente en comparación con métodos que no explotan información clínica contextual, como los de Amiri et al. [9] (88.21 %) o Tabibi et al. [10] (90.15 %).

La principal contribución metodológica reside en el mecanismo de pesos adaptativos del ensemble, que aprende dinámicamente la contribución óptima de cada modelo base durante el entrenamiento, superando consistentemente a las estrategias de ensemble estáticas. La fusión de metadatos demuestra ser una fuente de información complementaria que mejora la discriminación entre lesiones con características visuales similares, en línea con lo demostrado previamente por Gessert et al. [6] y Sun et al. [7].

Desde una perspectiva crítica, el trabajo presenta limitaciones en cuanto a la comparación con métricas heterogéneas, el coste computacional y el análisis cuantitativo de la interpretabilidad. Sin embargo, la evaluación externa en Derm7pt [18] y los tests estadísticos aportan evidencias sólidas sobre la fiabilidad de los resultados.

En conclusión, este trabajo ilustra el potencial de los enfoques multimodales en el diagnóstico dermatológico asistido por IA, y sienta las bases para el desarrollo de sistemas más generalizables, eficientes e interpretables que puedan ser adoptados en entornos clínicos reales.

Referencias

1. Saeed, M.A., Afify, Y.M., Badr, N.L., Helal, N.A.: Multimodal deep learning ensemble framework for skin cancer detection. *Scientific Reports* **15**, 45660 (2025). <https://doi.org/10.1038/s41598-025-30534-z>
2. Liao, H.: A Deep Learning Approach to Universal Skin Disease Classification. University of Rochester, Department of Computer Science (2016).
3. Kawahara, J., BenTaieb, A., Hamarneh, G.: Deep features to classify skin lesions. In: *IEEE 13th International Symposium on Biomedical Imaging (ISBI)*, pp. 1397–1400 (2016).
4. Bibi, S. et al.: MSRNet: Multiclass skin lesion recognition using additional residual block based fine-tuned deep models information fusion and best feature selection. *Diagnostics* **13**(19), 3063 (2023).
5. Nugroho, E.S., Ardiyanto, I., Nugroho, H.A.: Addressing imbalance ISIC-2019 dataset in dermoscopic pigmented skin lesion classification. *ICIC Express Letters* **18**(6), 563–573 (2024).
6. Gessert, N., Nielsen, M., Shaikh, M., Werner, R., Schlaefel, A.: Skin lesion classification using ensembles of multi-resolution EfficientNets with meta data. *MethodsX* **7**, 100864 (2020).
7. Sun, Q., Huang, C., Chen, M., Xu, H., Yang, Y.: Skin lesion classification using additional patient information. *BioMed Research International* **2021**, 6673852 (2021).
8. Yin, W., Huang, J., Chen, J., Ji, Y.: A study on skin tumor classification based on dense convolutional networks with fused metadata. *Frontiers in Oncology* **12**, 989894 (2022).
9. Amiri, S.A., Nasrolahzadeh, M., Mohammadpoory, Z., Kordkheili, A.H.Z.: Skin lesion classification via ensemble method on deep learning. *Multimedia Tools and Applications* **83**, 1–19 (2024).
10. Tabibi, S.T., Nikravanshalmani, A., Saboohi, H.: An ensemble classifier based on diverse convolutional neural networks for skin lesions classification. *IEEE Access* **12**, 10634499 (2024). <https://doi.org/10.1109/ACCESS.2024.10634499>
11. Firat, H., Üzen, H.: DXDSENet-CM model: An ensemble learning model based on depthwise Squeeze-and-Excitation ConvMixer architecture for the classification of multi-class skin lesions. *Multimedia Tools and Applications*, 1–36 (2024).
12. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778 (2016).
13. Chollet, F.: Xception: Deep learning with depthwise separable convolutions. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1251–1258 (2017).
14. Tan, M., Le, Q.: EfficientNet: Rethinking model scaling for convolutional neural networks. In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pp. 6105–6114 (2019).
15. Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P.: SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research* **16**, 321–357 (2002).
16. ISIC Archive: ISIC 2018: Skin Lesion Analysis Towards Melanoma Detection. The International Skin Imaging Collaboration (2018). <https://challenge2018.isic-archive.com/>
17. ISIC Archive: ISIC 2019: Skin Lesion Analysis Towards Melanoma Detection. The International Skin Imaging Collaboration (2019). <https://challenge2019.isic-archive.com/>

18. Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G.: Seven-point checklist and skin lesion classification using multitask multimodal neural nets. *IEEE Journal of Biomedical and Health Informatics* **23**(2), 538–546 (2019). <https://doi.org/10.1109/JBHI.2018.2839603>